

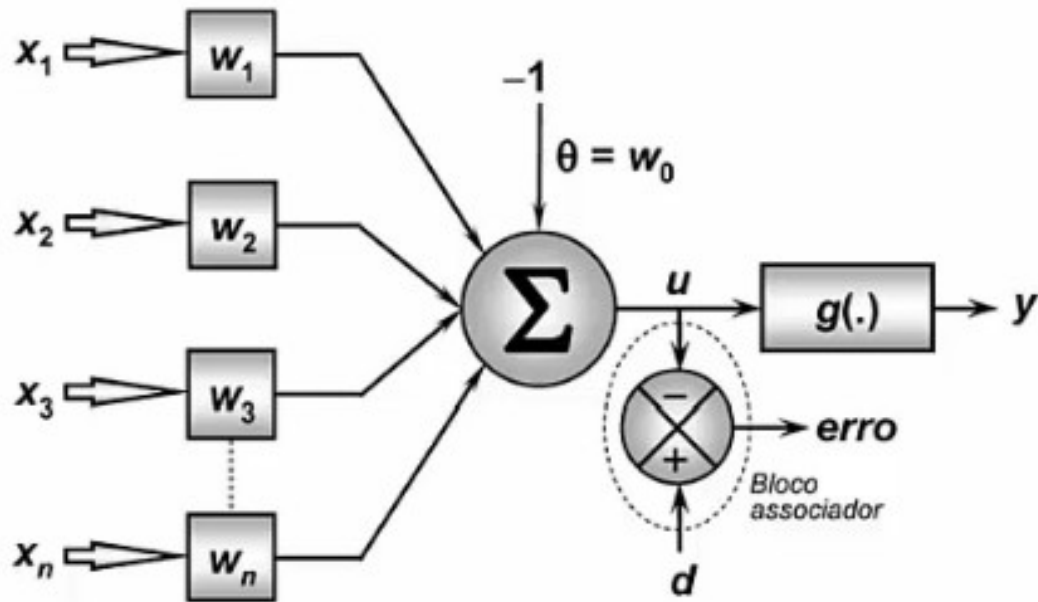
# Rede Adaline

A blue grid pattern background covering the bottom half of the slide.

# Adaline

- A rede Adaline (Adaptive Linear Element) proposta por Widrow e Hoff (1960) tem a mesma estrutura do Perceptron, diferenciando apenas no algoritmo de treinamento.
- Características da Adaline
  - Rede adaptativa
  - Inclusão de um algoritmo pioneiro para treinamento de redes de múltiplas camadas, o algoritmo de treinamento da Regra Delta
  - O algoritmo da Regra Delta é baseado no método dos mínimos quadrados.
  - Método de aprendizado mais suave

# Rede Adaline



$n$  sinais de entrada ( $x_1 \dots x_n$ ) e uma única saída ( $y$ ).

- O processamento se dá pelas seguintes expressões:

$$u = \sum_{i=1}^n w_i \cdot x_i - \theta \Leftrightarrow u = \sum_{i=0}^n w_i \cdot x_i$$

$$y = g(u)$$

- Onde:
- $x_i$  são os sinais de entrada,
- $w_i$  são os pesos sinápticos associados,
- $\theta$  é o bias (limiar de ativação),
- $g(.)$  é a função de ativação (degrau ou degrau bipolar) e
- $u$  é o potencial de ativação.

- O bloco associador demonstrado no diagrama acima tem uma função auxiliar no processo de treinamento da rede.
- 
- $\text{erro} = d - u$
- 
- Erro é igual ao valor esperado menos o valor do potencial de ativação produzido pela rede.

# Regra Delta



- O algoritmo de treinamento do Adaline é baseado no método dos mínimos quadrados, conhecido como Regra Delta.
- O algoritmo utiliza o método do gradiente descendente com a intenção de diminuir o valor da função de erro possibilitando assim a convergência para um mínimo da função de erro
- Objetivo: Realizar iterações locais para obter o ponto mínimo da função de erro e, assim, fixar os valores dos pesos quando o mínimo foi encontrado
- Funcionamento: Através de um ponto arbitrário (vetor de pesos iniciado aleatoriamente), o algoritmo percorre, a cada iteração a superfície da função de erro em direção ao ponto de mínimo.

- Então, temos:

$$\mathbf{w} \leftarrow \mathbf{w} + \eta \cdot (d^{(k)} - u) \cdot \mathbf{x}^{(k)}$$

- onde:  $\mathbf{w} = [\theta \ w_1 \ w_2 \ \dots \ w_n]^T$  é o vetor contendo o limiar e os pesos;
  - $\mathbf{x}^{(k)} = [-1 \ x_1^{(k)} \ x_2^{(k)} \ \dots \ x_n^{(k)}]^T$  é a  $k$ -ésima amostra de treinamento;
  - $d^{(k)}$  é o valor desejado para a  $k$ -ésima amostra de treinamento;
  - $u$  é o valor de saída do combinador linear; e
  - $\eta$  é uma constante que define a taxa de aprendizagem da rede.
- Dessa forma o processo de treinamento da rede Adaline procura mover continuamente o vetor de pesos buscando minimizar o erro quadrático em relação as amostras de dados disponíveis para aprendizado.

# Situação de convergência





- No Perceptron o hiperplano de separação das classes pode ter “infinitas disposições” pois a configuração final vetor de pesos ( $w$ ) é dependente dos valores iniciais aleatoriamente atribuídos.
- Na Adaline, a inclinação do hiperplano é ajustada por intermédio do método dos mínimos erros quadrados (LMS — least mean square), ou seja, independentemente dos valores inicialmente atribuídos ao vetor de pesos ocorrerá a busca pelo ótimo.

